



INTRODUCCIÓN A LA ROBÓTICA E1505

LOCALIZACIÓN EN ROBOTS MÓVILES



INTRODUCCIÓN A LA ROBÓTICA

Indice:

- 1 Localización.
- 2 Odometría.
- 3 Enfoques.
- 4 Localización probabilística.
- 5 Estimación bayesiana.
- 6 Filtro de Kalman.
- 7 Ejemplos Filtro de Kalman.



INTRODUCCIÓN A LA ROBÓTICA




Indice:

- 1** Localización.
- 2 Odometría.
- 3 Enfoques.
- 4 Localización probabilística.
- 5 Estimación bayesiana.
- 6 Filtro de Kalman.
- 7 Ejemplos Filtro de Kalman.



IR: 1 - LOCALIZACIÓN


Como podemos localizarnos en el mundo?





IR: 1 - LOCALIZACIÓN

Esquema genérico del proceso de localización.







IR: 1 - LOCALIZACIÓN

Desafíos.

- Ruido en los sensores.
- Aliasing de los sensores.
- Ruido en los actuadores





INTRODUCCIÓN A LA ROBÓTICA

Indice:


- 1 Localización.
- 2 Odometría.
- 3 Enfoques.
- 4 Localización probabilística.
- 5 Estimación bayesiana.
- 6 Filtro de Kalman.
- 7 Ejemplos Filtro de Kalman.



Odometría – Dead Reckoning

- Consiste en integrar (sumar) las distancias viajadas por el robot de forma de tener una estimación de su posición.
- Suponiendo un robot de tipo diferencial:

$$p = \begin{bmatrix} x \\ y \\ \theta \end{bmatrix}$$



$$\Delta x = \Delta s \cos(\theta + \Delta\theta/2)$$

$$\Delta y = \Delta s \sin(\theta + \Delta\theta/2)$$

$$\Delta s = \frac{\Delta s_r + \Delta s_l}{2}$$

$$\Delta\theta = \frac{\Delta s_r - \Delta s_l}{b}$$

b : distancia entre rueda motoras


- Una nueva posición puede ser escrita como:

$$p' = \begin{bmatrix} x' \\ y' \\ \theta' \end{bmatrix} = p + \begin{bmatrix} \Delta s \cos(\theta + \Delta\theta/2) \\ \Delta s \sin(\theta + \Delta\theta/2) \\ \Delta\theta \end{bmatrix} = \begin{bmatrix} x \\ y \\ \theta \end{bmatrix} + \begin{bmatrix} \Delta s \cos(\theta + \Delta\theta/2) \\ \Delta s \sin(\theta + \Delta\theta/2) \\ \Delta\theta \end{bmatrix}$$

Odometría – Dead Reckoning

- Finalmente podemos escribir la actualización de posición como:

$$p' = f(x, y, \theta, \Delta s_r, \Delta s_l) = \begin{bmatrix} x \\ y \\ \theta \end{bmatrix} + \begin{bmatrix} \frac{\Delta s_r + \Delta s_l}{2} \cos\left(\theta + \frac{\Delta s_r - \Delta s_l}{2b}\right) \\ \frac{\Delta s_r + \Delta s_l}{2} \sin\left(\theta + \frac{\Delta s_r - \Delta s_l}{2b}\right) \\ \frac{\Delta s_r - \Delta s_l}{b} \end{bmatrix}$$



- Dado por los errores de medición, la estimación de posición aumenta su error con el tiempo.
- Podemos definir la matriz de covarianza de la odometría como:

$$\Sigma_{\Delta} = covar(\Delta s_r, \Delta s_l) = \begin{bmatrix} k_r |\Delta s_r| & 0 \\ 0 & k_l |\Delta s_l| \end{bmatrix}$$

- Las k representan el error no determinístico presente en las ruedas.
- Podemos ver que suponemos:
 - Los errores de cada rueda son independientes
 - La varianza del error es proporcional a la distancia recorrida.

$$Cov(X, Y) = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{n}$$




Odometría – Dead Reckoning

- Utilizando propagación de errores y la expansión de Taylor de primer orden podemos llegar a:

$$\Sigma_{p'} = \nabla_p f \cdot \Sigma_p \cdot \nabla_p f^T + \nabla_{\Delta_{rl}} f \cdot \Sigma_{\Delta} \cdot \nabla_{\Delta_{rl}} f^T$$

$$F_p = \nabla_p f = \nabla_p(f^T) = \begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} & \frac{\partial f}{\partial \theta} \end{bmatrix} = \begin{bmatrix} 1 & 0 & -\Delta s \sin(\theta + \Delta\theta/2) \\ 0 & 1 & \Delta s \cos(\theta + \Delta\theta/2) \\ 0 & 0 & 1 \end{bmatrix}$$

$$F_{\Delta_{rl}} = \begin{bmatrix} \frac{1}{2} \cos\left(\theta + \frac{\Delta\theta}{2}\right) - \frac{\Delta s}{2b} \sin\left(\theta + \frac{\Delta\theta}{2}\right) & , & \frac{1}{2} \cos\left(\theta + \frac{\Delta\theta}{2}\right) + \frac{\Delta s}{2b} \sin\left(\theta + \frac{\Delta\theta}{2}\right) \\ \frac{1}{2} \sin\left(\theta + \frac{\Delta\theta}{2}\right) + \frac{\Delta s}{2b} \cos\left(\theta + \frac{\Delta\theta}{2}\right) & , & \frac{1}{2} \sin\left(\theta + \frac{\Delta\theta}{2}\right) - \frac{\Delta s}{2b} \cos\left(\theta + \frac{\Delta\theta}{2}\right) \\ \frac{1}{b} & & -\frac{1}{b} \end{bmatrix}$$



- Lo importante aquí es notar que la matriz de covarianza de la actualización depende de la matriz de covarianza del estado anterior, partiendo de un valor inicial.**



INTRODUCCIÓN A LA ROBÓTICA


Indice:

- 1 Localización.
- 2 Odometría.
- 3 Enfoques.**
- 4 Localización probabilística.
- 5 Estimación bayesiana.
- 6 Filtro de Kalman.
- 7 Ejemplos Filtro de Kalman.



IR: 3 – ENFOQUES


Navegación basada en localización vs. programada.






Navegación basada en localización vs. programada.

- Arquitecturas basadas en comportamientos (No realizan localización del robot propiamente dicho, pero si necesitan una “guía” al objetivo).




- Arquitecturas de navegación basadas en mapas.









Hipótesis de creencias.

- En las arquitecturas de navegación basadas en mapas, el robot debe tener una representación o modelo del ambiente (mapa).
- Y además una representación de su **creencia (belief)** respecto de su posición en el mismo.
- Se desprenden dos tipos de representación:
 - Creencia de hipótesis única
 - Creencia de hipótesis múltiples.



Hipótesis de creencias.


- Ejemplo hipótesis única en diferentes tipos de mapas.





Hipótesis de creencias.

- Ejemplo hipótesis múltiple.





INTRODUCCIÓN A LA ROBÓTICA

Indice:


- 1 Localización.
- 2 Odometría.
- 3 Enfoques.
- 4 Localización probabilística.**
- 5 Estimación bayesiana.
- 6 Filtro de Kalman.
- 7 Ejemplos Filtro de Kalman.



IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización probabilística

- Especifican probabilidades con la posición del robot.
- Parte de la idea de que los sensores poseen errores por tanto solo puede decirse con una cierta probabilidad si el robot está en una dada posición.
- Representan incertidumbre mediante teoría de probabilidad.
- En estos enfoques el problema de localización se resuelve en dos pasos:
 - **Actualización de predicción:** utilizando sensores interoceptivos el robot estima su posición, por ejemplo, mediante encoders en sus ruedas.
 - **Actualización de percepción:** el robot usa información de sus sensores exteroceptivos para corregir la posición estimada en el paso previo.





IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Repaso de probabilidad

- Probabilidad de que una variable aleatoria X tome un valor x

$$p(X = x)$$

- Función de densidad de probabilidad (PDF) (espacio continuos)

$$\sum_x p(x) = 1 \quad \int_x p(x) dx = 1$$

- Distribución Gaussiana escalar

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad p(x) = N(\mu, \sigma^2)$$

- Distribución Gaussiana multivariable


$$p(x) = \frac{1}{(2\pi)^{k/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right)$$

- Distribución conjunta

$$p(x, y)$$

Caso particular de variables aleatorias independientes:

$$p(x, y) = p(x)p(y)$$





IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Repaso de probabilidad

- Probabilidad condicional

$$p(x|y) = \frac{p(x,y)}{p(y)}$$

Para el caso de variables independientes

$$p(x|y) = \frac{p(x)p(y)}{p(y)} = p(x)$$

- Teorema de la probabilidad total

$$p(x) = \sum_y p(x|y)p(y)$$

$$p(x) = \int_y p(x|y)p(y)dy$$

- Regla de bayes

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)}$$

Como $p(y)$ no depende de x , este término se toma como una normalización, por lo que la regla de bayes puede escribirse como:

$$p(x|y) = \eta p(y|x)p(x)$$

- Probabilidad previa y posterior



IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Terminología


- Posición del robot $x_t = [x, y, \theta]^T$
- Camino del robot $X_T = \{x_0, x_1, x_2, \dots, x_T\}$
- Secuencia de lecturas de sensores interoceptivos $U_T = \{u_0, u_1, u_2, \dots, u_T\}$
- Secuencia de lecturas de sensores exteroceptivos (observaciones, lectura de información) $Z_T = \{z_0, z_1, z_2, \dots, z_T\}$
- Vector con las coordenadas de los puntos de referencia en el mapa $M = \{m_0, m_1, m_2, \dots, m_{n-1}\}$
- Distribución de **creencia (belief)**, se representan mediante distribuciones de probabilidad condicional:

$$bel(x_t) = p(x_t | z_{1 \rightarrow t}, u_{1 \rightarrow t})$$

Representa la probabilidad del robot estando en x_t dadas las pasadas observaciones z y entradas de control u

Sin considerar la nueva observación, recibe el nombre de **predicción**, y al considerarla corrección o **actualización**:

$$\overline{bel}(x_t) = p(x_t | z_{1 \rightarrow t-1}, u_{1 \rightarrow t}) \longrightarrow bel(x_t) = p(x_t | z_{1 \rightarrow t}, u_{1 \rightarrow t})$$







IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Elementos necesarios para la localización probabilística

- La distribución de probabilidad inicial (uniforme, delta de Dirac, gaussiana, etc.)
- Mapa del ambiente (o ubicación de las referencias del mismo)
- Datos de sensores (interoceptivos y exteroceptivos)
- Un modelo probabilístico del movimiento del robot $x_t = f(x_{t-1}, u_t)$
- Un modelo probabilístico de las mediciones del ambiente $z_t = h(x_t, M)$

Ejemplo:






$$z_t = h(x_t, M)$$

$$h(x_t, M) = 10 - x_t$$

$$p(z_t | x_t, M) = N(h(x_t, M), R_t)$$

Clasificación de problemas de localización

- Traqueo de posición.
- Localización global
- Problema del robot secuestrado.





IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov

- La localización de Markov rastrea el estado de creencia del robot usando una densidad de probabilidad arbitraria para representar la posición del robot.
- En la práctica todos los procesos de localización de Markov utilizan un espacio discreto para ubicar al robot.
- La localización de Markov puede resolver el **problema de localización global, de seguimiento de posición y de robot secuestrado**.
- Se basa en la iteración de los estados de **predicción** (utilizando el teorema de probabilidad total) y **actualización por medida externa** (utilizando la regla de Bayes).



A. A. Mapson (1886).



IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov – Etapa de predicción.

- Esta etapa estima la posición actual del robot basado en el conocimiento de la posición previa y de la odometría de entrada.
- El **teorema de la probabilidad total** es utilizado para calcular la creencia actual en función de la creencia previa y datos propioceptivos (como lectura de encoders o entradas de control) u_t :

$$\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

Caso continuo

$$\overline{bel}(x_t) = \sum_{x_{t-1}} p(x_t | u_t, x_{t-1}) bel(x_{t-1})$$

Caso discreto

- Se puede ver que la creencia en x_t es la integral (o suma) de dos distribuciones. **Para calcular la probabilidad de posición x_t en el nuevo estado de creencia, se debe integrar sobre todas las formas posibles en las que el robot puede haber llegado a x_t de acuerdo con las posiciones potenciales expresadas en el estado de creencia anterior. El mismo lugar puede ser alcanzado desde varias ubicaciones de origen con la misma medida del encoder u_t ya la misma es incierta.**
- Observar que la **integral (o suma) debe hacerse en todas las posibles posiciones del robot.**
- Observar que las ecuaciones anteriores pueden ser vistas como la **convolución** entre la creencia previa $bel(x_{t-1})$ y el modelo probabilístico de movimiento $p(x_t | u_t, x_{t-1})$.



IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov – Etapa de actualización.

- En esta fase el robot corrige su posición anterior (es decir, su creencia anterior) combinándola oportunamente con la información de sus sensores exteroceptivos.
- La regla de Bayes es utilizada para calcular la nueva creencia, en función de la creencia previa y la información adquirida z_t :

$$bel(x_t) = \eta p(z_t | x_t, M) \overline{bel}(x_t)$$

- $p(z_t | x_t, M)$ es el **modelo de medición probabilístico**, es decir, la probabilidad de observar los datos de medición z_t dado el conocimiento del mapa M y de la posición del robot x_t .
- Por lo tanto, el nuevo estado de creencia es simplemente el producto entre el modelo de medición probabilística y el estado de creencia anterior.
- Observar que la ecuación anterior **actualiza todas las poses posibles del robot**.



IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov – Algoritmo

```
for all  $x_t$  do
     $\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$  (prediction update)
     $bel(x_t) = \eta p(z_t | x_t, M) \overline{bel}(x_t)$  (measurement update)
endfor
return  $bel(x_t)$ 
```

- El desafío crítico en la localización de Markov es el cálculo de $p(z_t | x_t, M)$. El modelo de sensor debe calcular la probabilidad de una medida perceptiva específica dada la ubicación del robot y el mapa del entorno. Se utilizan tres **suposiciones clave para construir este modelo de sensor**:
 - Si un objeto en el mapa es detectado, **la medida del error puede describirse con una distribución con media en la lectura correcta.**
 - Siempre debe haber una probabilidad **distinta de cero** de que un sensor lea cualquier medida.
 - Hay un **pico local** en la distribución de densidad de probabilidad en la lectura máxima del sensor.



IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov – Suposición de Markov

```
for all  $x_t$  do
   $\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$  (prediction update)
   $bel(x_t) = \eta p(z_t | x_t, M) \overline{bel}(x_t)$  (measurement update)
endfor
return  $bel(x_t)$ 
```

- **Suposición de Markov:** Implica que la salida x_t es una función sólo del estado anterior del robot x_{t-1} y sus acciones más recientes (odometría) u_t y percepción z_t .
- En una situación general, **no markoviana**, el estado de un sistema depende de toda su historia.






IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov – Funcionamiento


- El robot inicia su funcionamiento sin conocer su posición inicial.
- Tomamos una distribución uniforme sobre todas las posibles ubicaciones.
- El robot toma una medida de distancia y detecta que se encuentra cerca de un pilar (etapa de actualización).
- El robot se desplaza, ver que el modelo de movimiento afecta a la creencia de posición.





Localización de Markov – Funcionamiento

- El robot toma una nueva medida de distancia y detecta que se encuentra cerca de un pilar (etapa de actualización).



- Luego de varios ciclos del proceso el robot tiene una cierta “confianza de donde se encuentra”



IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov – Ejemplo 1D

- Supongamos que nuestro espacio de trabajo esta dividido en 10 celdas equivalentes.
- Supongamos que la creencia original del robot es una distribución uniforme entre los elementos 0 y 3.
- Supongamos que la figura b) representa el modelo de movimiento probabilístico del robot. (este modelo implica que entre el tiempo 0 y 1 el robot pudo moverse a la celda 2 o 3).
- Si el robot realizo este movimiento debemos actualizar la creencia de posición (etapa de predicción)

$$\bar{bel}(x_1) = \sum_{x_0=0}^3 p(x_1|u_1, x_0) bel(x_0)$$






$$p(x_1 = 2) = p(x_0 = 0)p(u_1 = 2) = 0.125,$$

$$p(x_1 = 3) = p(x_0 = 0)p(u_1 = 3) + p(x_0 = 1)p(u_1 = 2) = 0.25$$

$$p(x_1 = 4) = p(x_0 = 1)p(u_1 = 3) + p(x_0 = 2)p(u_1 = 2) = 0.25$$

$$p(x_1 = 5) = p(x_0 = 2)p(u_1 = 3) + p(x_0 = 3)p(u_1 = 2) = 0.25$$

$$p(x_1 = 6) = p(x_0 = 3)p(u_1 = 3) = 0.125$$










IR: 4 – LOCALIZACIÓN PROBABILÍSTICA

Localización de Markov – Ejemplo 1D

- Asumiendo que el robot utiliza algún sensor de medición de distancia para medir la distancia z al origen.
- Asumiendo que el modelo probabilístico de la medida es la figura d), este grafico nos dice que la distancia puede ser 5 o 6 celdas.
- Ahora nos encontramos en una etapa de actualización del método de Markov, por tanto aplicando la regla de Bayes:

$$bel(x_1) = \eta p(z_1|x_1, M) \overline{bel}(x_1)$$

- Finalmente se actualiza la creencia de posición final de acuerdo a la lectura, para este caso $\eta = 5,33$ para que la creencia quede normalizada a uno.





INTRODUCCIÓN A LA ROBÓTICA

Indice:

- 1 Localización.
- 2 Odometría.
- 3 Enfoques.
- 4 Localización probabilística.
- 5 Estimación bayesiana.**
- 6 Filtro de Kalman.
- 7 Ejemplos Filtro de Kalman.



IR: 2 – ESTIMACIÓN BAYESIANA

Estimación bayesiana

- Dado el modelo de proceso:

$$\frac{dX(t)}{dt} = F(X(t), u(t)) \quad \text{siendo } X(t) \in R^n \text{ el vector de estados}$$

$$y(t) = h(X(t)), \quad t \in \{t_1, t_2, \dots\} \quad \text{salidas del sistema}$$

- Si queremos observar los estados del sistema:

- Si:

- $F()$ y $h()$ no tienen incertidumbre
- Las mediciones están libres de ruido
- Sistema observable



Puedo usar observadores
determinísticos para estimar
los estados del sistema



IR: 2 – ESTIMACIÓN BAYESIANA

Estimación bayesiana

- En la realidad:
 - $F()$ y $h()$ no son perfectamente conocidas.
 - Condiciones iniciales afectas por incertidumbre.
 - Salidas del sistema contaminadas con ruido.

- Matemáticamente lo podemos expresar como:

$$\frac{dX(t)}{dt} = F(X(t), u(t), \xi(t))$$

$$\hat{X}_0 = X_0 + \mu$$

$$y(t_i) = h(X(t_i), \eta(t_i))$$

Variables aleatorias

- Una versión simplificada de lo anterior expresa la incertidumbre en forma aditiva:

$$\frac{dX(t)}{dt} = F(X(t), u(t)) + \xi(t)$$

$$y(t_i) = h(X(t_i)) + \eta(t_i)$$

- Esto puede justificarse pensando que el error entre la medida real y el modelado es una variable aleatoria ξ

$$\xi(t) = \frac{dX(t)}{dt} - F(X(t), u(t))$$

Modelo nominal

Modelo real



IR: 2 – ESTIMACIÓN BAYESIANA

Estimación bayesiana

- Con el modelo anterior podemos recurrir a la estimación bayesiana.
- Esta se basa en aplicar la Regla de bayes en forma iterativa:

$$p_{x|y}(x|y) = \frac{p_{y|x}(y|x) \cdot p_x(x)}{p_y(y)}$$

- Hay una gran teoría que demuestra la convergencia de los estimadore bayesianos.





Estimación bayesiana

- **Aproximación iterativa:**
 - Consideremos dos variables aleatorias (x, y) , de las cuales conocemos que existe una distribución de probabilidad conjunta que las describe: $p_{x,y}(x, y)$
 - **Nos interesa estimar x , pero no tenemos medidas de la misma**
 - **No nos interesa y pero podemos obtener medidas de la misma**
 - **No conocemos $p_{x,y}(x, y)$, pero sabemos que ambas variables aleatorias no son independientes.**



IR: 2 – ESTIMACIÓN BAYESIANA

Estimación bayesiana

$$p_{x|y}(x|y) = \frac{p_{y|x}(y|x) \cdot p_x(x)}{p_y(y)}$$

- **Aproximación iterativa:**

- Explotaremos la regla de bayes para obtener información de la variable aleatoria x
- $p_{y|x}(y|x)$ es la probabilidad condicional de y dado x
- Si fijamos y a un valor dado esta función se vuelve solo función de x

-> “**zona de probabilidad de x** ” (likelihood)

- Nos dice la probabilidad de los valores de x dado un y fijo -> **No es una distribución de probabilidad**

- Ejemplo:

$$L(x, y) = p_{r|y, x}(r=10|x, y) = \begin{cases} =1 & \forall (x, y) \text{ / } 9.99 \leq \sqrt{(x-5)^2 + (y-8)^2} \leq 10.01 \\ =0 & \text{otherwise} \end{cases}$$

- Ejemplo:

$$L_{\text{thanks to mama}}(x, y) = \begin{cases} =1 & \forall (x, y) \in \text{Kitchen} \\ =0 & \forall (x, y) \notin \text{Kitchen} \end{cases} \quad \begin{array}{c} \text{Si mamá puede} \\ \text{equivocarse} \end{array} \quad \longrightarrow \quad L_{\text{thanks to mama}}(x, y) = \begin{cases} =1 & \forall (x, y) \in \text{Kitchen} \\ =0.01 & \forall (x, y) \notin \text{Kitchen} \end{cases}$$



IR: 2 – ESTIMACIÓN BAYESIANA

Estimación bayesiana

- **Aproximación iterativa:**

- Supongamos que tenemos medidas de y
- Supongamos que conocemos probabilidad condicional de y dado x $p_{y|x}(y|x)$
 - > con cada nueva medida podemos obtener una nueva **likelihood**

Probabilidad posterior

Dato conocido (likelihood)

Probabilidad previa, por ejemplo una distribución uniforme

$$p_{x|y}(x|y=y_0) = \frac{p_{y|x}(y=y_0|x) \cdot p_{x,0}(x)}{p_y(y_0)}$$

Si llega nueva medida de y ->
vuelvo a aplicar regla.
“Posterior” pasa a “Previa”

No lo conozco, pero no me importa. Solo es un factor de escala para que la densidad de probabilidad resultante tenga volumen 1. Igualmente lo puede determinar como:

$$p_y(y_0) = \int_{\text{domain of } x} p_{y|x}(y=y_0|x) \cdot p_{x,0}(x) \cdot dx$$



IR: 2 – ESTIMACIÓN BAYESIANA

Estimación bayesiana

- **Aproximación iterativa:**

- Podemos escribir:

$$p_{x|y}(x | y = y_0) \propto p_{y|x}(y = y_0 | x) \cdot p_{x,0}(x)$$

- **Con cada nueva medida**

$$p_{x|Y}(x | Y = \{y_0, y_1\}) \propto p_{y|x}(y = y_1 | x) \cdot p_{x|y}(x | y = y_0)$$

$\vdots$

$$p_{x|Y}(x | Y = \{y_i\}_{i=0}^K) \propto p_{y|x}(y = y_K | x) \cdot p_{x|Y}(x | Y = \{y_i\}_{i=0}^{K-1})$$

**Creencia de x basada
en secuencia de
likelihoods**

$$\{L_j(x)\}_{j=1}^i$$

$$p_x^k(x) \propto L_k(x) \cdot p_x^{k-1}(x)$$



IR: 2 – ESTIMACIÓN BAYESIANA

Estimación bayesiana

- **Aproximación iterativa:**

- Notar que si tenemos una serie de observaciones:

$$y_0 = h_0(x) + \eta_0$$

$$y_1 = h_1(x) + \eta_1$$

...

$$y_M = h_M(x) + \eta_M$$

Ver que podrían provenir de distintos tipos de sensores

-> la estimación bayesiana nos permite realizar fusión de datos

- h_i puede ser no lineal
 - Las distintas h_i pueden no ser iguales
 - Las componentes de ruido $\{\eta_i\}$ pueden tener distintas distribuciones de probabilidad

- **Lo único que se asume es que las fuentes de ruido son independientes**

$$p_{(\eta_i, \eta_j)}(\eta_i, \eta_j) = p_{\eta_i}(\eta_i) \cdot p_{\eta_j}(\eta_j), \quad \forall (i, j) \quad / \quad i \neq j$$



Como estimar un sistema dinámico?

- Considerando el modelo de proceso puede aproximar por:

$$x(k+1) = F(x(k), u(k)) + \xi(k)$$

- Esto es similar a tener la suma de dos variables aleatorias **independientes**:

$$z = x + \xi$$

- Si calculamos la densidad de probabilidad de la nueva variable aleatoria z obtenemos:

$$p_z(z) = \int_{\text{domain of } \xi} p_x(z - \xi) \cdot p_\xi(\xi) \cdot d\xi$$

- Ver que se trata de una convolución -> salvo que p_x sea una delta, p_z será más difusa que p_x (**será menos informativa**)



Como estimar un sistema dinámico?

- Para estimar un sistema dinámico tendré dos pasos:
- Aplico modelo y obtengo distribución de probabilidad de la nueva variable aleatoria $x(k)$ basada en $x(k-1)$

$$p_{x(k)|Y(k-1)}(x(k)|Y(k-1)) = \text{Prediction}(p_{x(k-1)|Y(k-1)}(x(k-1)|Y(k-1)))$$

Predicción

- Cuando lleguen medidas de y aplico Regla de Bayes y actualizo creencia de $x(k)$


$$p_{x(k)|Y(k)}(x(k)|Y(k)) \propto p_{y(k)|x(k)}(y(k)=y_K|x(k)) \cdot p_{x(k)|Y(k-1)}(x(k)|Y(k-1))$$

Actualización



IR: 2 – ESTIMACIÓN BAYESIANA

Como estimar un sistema dinámico?





INTRODUCCIÓN A LA ROBÓTICA

Indice:


- 1 Localización.
- 2 Odometría.
- 3 Enfoques.
- 4 Localización probabilística.
- 5 Estimación bayesiana.
- 6 Filtro de Kalman.**
- 7 Ejemplos Filtro de Kalman.



IR: 3 – FILTRO DE KALMAN

Filtro de kalman

- Se trata de un estimador óptimo para cuando el proceso y las mediciones **ruido gaussiano con media cero.**
- **Ruido en modelo y ruido en sensores debe ser con distribución normal.**





IR: 3 – FILTRO DE KALMAN

Filtro de Kalman solo para sistemas lineales

- Considerando el modelo LTI discreto:

$$\mathbf{x}\langle k+1\rangle = \mathbf{F}\mathbf{x}\langle k\rangle + \mathbf{G}\mathbf{u}\langle k\rangle + \mathbf{v}\langle k\rangle \quad \mathbf{v}\langle k\rangle \sim N(0, \mathbf{V})$$

$$\mathbf{z}\langle k\rangle = \mathbf{H}\mathbf{x}\langle k\rangle + \mathbf{w}\langle k\rangle \quad \mathbf{w}\langle k\rangle \sim N(0, \mathbf{W})$$

- El filtro de Kalman tendrá dos pasos:

- Predicción:**

$$\hat{\mathbf{x}}^+\langle k+1\rangle = \mathbf{F}\hat{\mathbf{x}}\langle k\rangle + \mathbf{G}\mathbf{u}\langle k\rangle$$

$$\hat{\mathbf{P}}^+\langle k+1\rangle = \mathbf{F}\hat{\mathbf{P}}\langle k\rangle\mathbf{F}^T + \hat{\mathbf{V}}$$

- Actualización**

$$\hat{\mathbf{x}}\langle k+1\rangle = \hat{\mathbf{x}}^+\langle k+1\rangle + \mathbf{K}\nu$$

$$\hat{\mathbf{P}}\langle k+1\rangle = \hat{\mathbf{P}}^+\langle k+1\rangle - \mathbf{K}\mathbf{H}\hat{\mathbf{P}}^+\langle k+1\rangle$$

Donde:

Innovación: $\nu = \mathbf{z}^\# \langle k+1\rangle - \mathbf{H}\hat{\mathbf{x}}^+\langle k+1\rangle \in \mathbb{R}^p$

Ganancia de Kalman

$$\mathbf{K} = \mathbf{P}^+\langle k+1\rangle \mathbf{H}^T \left(\underbrace{\mathbf{H}\mathbf{P}^+\langle k+1\rangle\mathbf{H}^T + \hat{\mathbf{W}}}_{\text{covarianza}} \right)^{-1} \in \mathbb{R}^{n \times p}$$

La matriz de covarianza puede acumular errores numéricos calculada en esta forma una alternativa es utilizar la forma de Joseph:

$$\hat{\mathbf{P}}\langle k+1\rangle = (\mathbf{I}_{n \times n} - \mathbf{K}\mathbf{H})\hat{\mathbf{P}}^+\langle k+1\rangle(\mathbf{I}_{n \times n} - \mathbf{K}\mathbf{H})^T + \mathbf{K}\hat{\mathbf{V}}\mathbf{K}^T$$



IR: 3 – FILTRO DE KALMAN

Filtro de Kalman Extendido - sistemas no lineales

- Considerando un sistema no lineal discreto:

$$\mathbf{x}_{\langle k+1 \rangle} = f(\mathbf{x}_{\langle k \rangle}, \mathbf{u}_{\langle k \rangle}, \mathbf{v}_{\langle k \rangle})$$

$$\mathbf{z}_{\langle k \rangle} = \mathbf{h}(\mathbf{x}_{\langle k \rangle}, \mathbf{w}_{\langle k \rangle})$$

- Podemos linealizar el sistema en el estado estimado $\hat{\mathbf{x}}_k$ como:

$$\mathbf{x}'_{\langle k+1 \rangle} \approx \mathbf{F}_x \mathbf{x}'_{\langle k \rangle} + \mathbf{F}_u \mathbf{u}_{\langle k \rangle} + \mathbf{F}_v \mathbf{v}_{\langle k \rangle}$$

$$\mathbf{z}'_{\langle k \rangle} \approx \mathbf{H}_x \mathbf{x}'_{\langle k \rangle} + \mathbf{H}_w \mathbf{w}_{\langle k \rangle}$$


Donde:

$$\mathbf{F}_x = \partial \mathbf{f} / \partial \mathbf{x} \in \mathbb{R}^{n \times n}, \mathbf{F}_u = \partial \mathbf{f} / \partial \mathbf{u} \in \mathbb{R}^{n \times m}$$

$$\mathbf{F}_v = \partial \mathbf{f} / \partial \mathbf{v} \in \mathbb{R}^{n \times n}, \mathbf{H}_x = \partial \mathbf{h} / \partial \mathbf{x} \in \mathbb{R}^{p \times n}$$

$$\mathbf{H}_w = \partial \mathbf{h} / \partial \mathbf{w} \in \mathbb{R}^{p \times p}$$

son los jacobianos de $\mathbf{h}$ y $\mathbf{f}$.





IR: 3 – FILTRO DE KALMAN

Filtro de Kalman Extendido - sistemas no lineales

- Considerando un sistema no lineal discreto:

$$\mathbf{x}\langle k+1\rangle = f(\mathbf{x}\langle k\rangle, \mathbf{u}\langle k\rangle, \mathbf{v}\langle k\rangle)$$

$$\mathbf{z}\langle k\rangle = \mathbf{h}(\mathbf{x}\langle k\rangle, \mathbf{w}\langle k\rangle)$$

- El filtro de Kalman tendrá dos pasos:

- Predicción:**

$$\hat{\mathbf{x}}^+\langle k+1\rangle = \mathbf{f}(\hat{\mathbf{x}}\langle k\rangle, \mathbf{u}\langle k\rangle)$$

$$\hat{\mathbf{P}}^+\langle k+1\rangle = \mathbf{F}_x \hat{\mathbf{P}}\langle k\rangle \mathbf{F}_x^T + \mathbf{F}_v \hat{\mathbf{V}} \mathbf{F}_v^T$$

- Actualización**

$$\hat{\mathbf{x}}\langle k+1\rangle = \hat{\mathbf{x}}^+\langle k+1\rangle + \mathbf{K}\nu$$

$$\hat{\mathbf{P}}\langle k+1\rangle = \hat{\mathbf{P}}^+\langle k+1\rangle - \mathbf{K} \mathbf{H}_x^T \hat{\mathbf{P}}^+\langle k+1\rangle$$

Un problema con el EKF es que las distribuciones de las VA. resultantes no son gaussianas, por tanto no se trata de un filtro optimo

Ganancia de Kalman

$$\mathbf{K} = \mathbf{P}^+\langle k+1\rangle \mathbf{H}_x^T \left(\mathbf{H}_x \mathbf{P}^+\langle k+1\rangle \mathbf{H}_x^T + \mathbf{H}_w \hat{\mathbf{W}} \mathbf{H}_w^T \right)^{-1}$$



IR: 3 – FILTRO DE KALMAN

Filtro de Kalman Extendido - sistemas no lineales

Procedure EKF

Input : $\hat{\mathbf{x}}\langle k \rangle \in \mathbb{R}^n$, $\hat{\mathbf{P}}\langle k \rangle \in \mathbb{R}^{n \times n}$, $\mathbf{u}\langle k \rangle \in \mathbb{R}^m$, $\mathbf{z}\langle k+1 \rangle \in \mathbb{R}^p$, $\hat{\mathbf{V}} \in \mathbb{R}^{n \times n}$, $\hat{\mathbf{W}} \in \mathbb{R}^{p \times p}$

Output: $\hat{\mathbf{x}}\langle k+1 \rangle \in \mathbb{R}^n$, $\hat{\mathbf{P}}\langle k+1 \rangle \in \mathbb{R}^{n \times n}$

– *linearize about* $\mathbf{x} = \hat{\mathbf{x}}\langle k \rangle$

compute Jacobians: $\mathbf{F}_x \in \mathbb{R}^{n \times n}$, $\mathbf{F}_v \in \mathbb{R}^{n \times n}$, $\mathbf{H}_x \in \mathbb{R}^{p \times n}$, $\mathbf{H}_w \in \mathbb{R}^{p \times p}$

– *the prediction step*

$$\hat{\mathbf{x}}^+\langle k+1 \rangle = \mathbf{f}(\hat{\mathbf{x}}\langle k \rangle, \mathbf{u}\langle k \rangle) \quad // \text{predict state at next time step}$$

$$\hat{\mathbf{P}}^+\langle k+1 \rangle = \mathbf{F}_x \hat{\mathbf{P}}\langle k \rangle \mathbf{F}_x^T + \mathbf{F}_v \hat{\mathbf{V}} \mathbf{F}_v^T \quad // \text{predict covariance at next time step}$$


– *the update step*

$$\nu = \mathbf{z}\langle k+1 \rangle - \mathbf{h}(\hat{\mathbf{x}}^+\langle k+1 \rangle) \quad // \text{innovation : measured - predicted sensor value}$$

$$\mathbf{K} = \mathbf{P}^+\langle k+1 \rangle \mathbf{H}_x^T \left[\mathbf{H}_x \mathbf{P}^+\langle k+1 \rangle \mathbf{H}_x^T + \mathbf{H}_w \hat{\mathbf{W}} \mathbf{H}_w^T \right]^{-1} \quad // \text{Kalman gain}$$

$$\hat{\mathbf{x}}\langle k+1 \rangle = \hat{\mathbf{x}}^+\langle k+1 \rangle + \mathbf{K} \nu \quad // \text{update state estimate}$$

$$\hat{\mathbf{P}}\langle k+1 \rangle = \hat{\mathbf{P}}^+\langle k+1 \rangle - \mathbf{K} \mathbf{H}_x \hat{\mathbf{P}}^+\langle k+1 \rangle \quad // \text{update covariance estimate}$$





INTRODUCCIÓN A LA ROBÓTICA

Indice:

- 1 Localización.
- 2 Odometría.
- 3 Enfoques.
- 4 Localización probabilística.
- 5 Estimación bayesiana.
- 6 Filtro de Kalman.
- 7 Ejemplos Filtro de Kalman.**



IR: 4 – EJEMPLO FILTRO DE KALMAN

Estimación de pose

- Considerando el modelo de un robot diferencial como:

$$\mathbf{x}\langle k+1 \rangle = \mathbf{f}(\mathbf{x}\langle k \rangle, \delta\langle k \rangle, \mathbf{v}\langle k \rangle) = \begin{pmatrix} x\langle k \rangle + (\delta_d + v_d) \cos \theta\langle k \rangle \\ y\langle k \rangle + (\delta_d + v_d) \sin \theta\langle k \rangle \\ \theta\langle k \rangle + \delta_\theta + v_\theta \end{pmatrix}$$

- Donde:

k es el paso de tiempo

$\delta\langle k \rangle = (\delta_d, \delta_\theta)^T \in \mathbb{R}^{2 \times 1}$ es la medida de odometría

$\mathbf{v}\langle k \rangle = (v_d, v_\theta)^T \in \mathbb{R}^{2 \times 1}$ es el ruido aleatorio de medida

- Sin información que lo contradiga podemos suponer al ruido aleatorio como: $\mathbf{v} = (v_d, v_\theta)^T \sim N(0, V)$

- Con una matriz de covarianza: $V = \begin{pmatrix} \sigma_d^2 & 0 \\ 0 & \sigma_\theta^2 \end{pmatrix}$

- Estimar la matriz de covarianza no es fácil, usualmente se obtiene de ensayos experimentales o se estima



IR: 4 – EJEMPLO FILTRO DE KALMAN

Estimación de pose

- Asumiendo que el ruido es gaussiano y de media cero el filtro extendido de Kalman provee una estimación optima de la pose: $\mathbf{x} = (x_v, y_v, \theta_v)^T$
- Para este caso las ecuaciones de predicción son:

$$\hat{\mathbf{x}}^{+}_{\langle k+1 \rangle} = \mathbf{f}(\hat{\mathbf{x}}_{\langle k \rangle}, \hat{\mathbf{u}}_{\langle k \rangle})$$

$$\hat{\mathbf{P}}^{+}_{\langle k+1 \rangle} = \mathbf{F}_x \hat{\mathbf{P}}_{\langle k \rangle} \mathbf{F}_x^T + \mathbf{F}_v \hat{\mathbf{V}} \mathbf{F}_v^T$$

con:

$$\mathbf{x}_{\langle k+1 \rangle} = \mathbf{f}(\mathbf{x}_{\langle k \rangle}, \delta_{\langle k \rangle}, \mathbf{v}_{\langle k \rangle}) = \begin{pmatrix} x_{\langle k \rangle} + (\delta_d + v_d) \cos \theta_{\langle k \rangle} \\ y_{\langle k \rangle} + (\delta_d + v_d) \sin \theta_{\langle k \rangle} \\ \theta_{\langle k \rangle} + \delta_\theta + v_\theta \end{pmatrix}$$

$$\mathbf{F}_x = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\mathbf{v}=0} = \begin{pmatrix} 1 & 0 & -\delta_d \sin \theta_v \\ 0 & 1 & \delta_d \cos \theta_v \\ 0 & 0 & 1 \end{pmatrix}$$

$$\mathbf{F}_v = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{v}} \right|_{\mathbf{v}=0} = \begin{pmatrix} \cos \theta_v & 0 \\ \sin \theta_v & 0 \\ 0 & 1 \end{pmatrix}$$



Se evalúa en $\mathbf{v} = \mathbf{0}$, ya que el ruido no puede medirse, por tanto se toma su valor medio



IR: 4 – EJEMPLO FILTRO DE KALMAN

Estimación de pose

```
close all
clear all
V=diag([0.02, 0.5*pi/180].^2); %
matriz de covarianza del modelo
veh=Bicycle('covar',V) % genero modelo
veh.add_driver(RandomPath(10)) %
genero camino 10 puntos aleatorios
%veh.run() %si quiero ver animacion
P0=diag([0.005, 0.005, 0.001].^2)
%matriz de covarianza inicial para EKF
ekf=EKF(veh,V,P0) % constructor del
filtro
ekf.run(250) %corre filtro
veh.plot_xy('b') % muestro recorrido
real "ground truth"
hold on
ekf.plot_xy('r') % muestro estimacion
recorrido robot con EKF
ekf.plot_ellipse('g') % grafico
elipces de confianza 95% cada 20
muestras
legend('real','con EKF')
figure();
ekf.plot_P(); %grafico (det(p))^0.5
muestra crecimiento de incerteza en
la estimacion
```





IR: 4 – EJEMPLO FILTRO DE KALMAN

Localización con un mapa

- Suponiendo tener un mapa y que el mismo tiene algún tipo de faro (landmark) que permite ubicarnos respecto de él, podemos utilizar el filtro de Kalman para realizar una estimación de posición.
- Suponiendo que el robot es equipado con un sonar que provee observaciones de los faros respecto del robot:

$$z = h(x, p_i)$$

- Donde

$x = (x_v, y_v, \theta_v)^T$ Es el estado del robot

$p_i = (x_i, y_i)^T$ Es la posición conocida del i-faro en el marco global.

- La observación puede escribirse como:

$$z = h(x, p_i) = \begin{pmatrix} \sqrt{(y_i - y_v)^2 + (x_i - x_v)^2} \\ \tan^{-1}(y_i - y_v)/(x_i - x_v) - \theta_v \end{pmatrix} + \begin{pmatrix} w_r \\ w_\beta \end{pmatrix}$$

- Donde $z = (r, \beta)^T$

- Siendo r la distancia y β el ángulo al faro, además: $\begin{pmatrix} w_r \\ w_\beta \end{pmatrix} \sim N(0, W), \quad W = \begin{pmatrix} \sigma_r^2 & 0 \\ 0 & \sigma_\beta^2 \end{pmatrix}$



IR: 4 – EJEMPLO FILTRO DE KALMAN

Localización con un mapa

- En este caso la diferencia entre la observación y la observación estimada constituye la llamada innovación (representa nueva información):

$$\nu = z^{\#}_{\langle k+1 \rangle} - h(\hat{x}^{+}_{\langle k+1 \rangle}, p_i)$$

- Para procesar nueva información:

- Actualización:**

$$\hat{x}_{\langle k+1 \rangle} = \hat{x}^{+}_{\langle k+1 \rangle} + K\nu$$

$$\hat{P}_{\langle k+1 \rangle} = \hat{P}^{+}_{\langle k+1 \rangle} - KH_x \hat{P}^{+}_{\langle k+1 \rangle}$$

$$K = P^{+}_{\langle k+1 \rangle} H_x^T S^{-1}$$

$$S = H_x P^{+}_{\langle k+1 \rangle} H_x^T + H_w \hat{W} H_w^T$$

Con:

$$H_x = \left. \frac{\partial h}{\partial x} \right|_{w=0} = \begin{pmatrix} -\frac{x_i - x_v}{r} & -\frac{y_i - y_v}{r} & 0 \\ \frac{y_i - y_v}{r^2} & -\frac{x_i - x_v}{r^2} & -1 \end{pmatrix} \quad H_w = \left. \frac{\partial h}{\partial w} \right|_{w=0} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$



IR: 4 – EJEMPLO FILTRO DE KALMAN

Localización con un mapa

$$\hat{\mathbf{x}}^{+}_{\langle k+1 \rangle} = \mathbf{f}(\hat{\mathbf{x}}_{\langle k \rangle}, \hat{\mathbf{u}}_{\langle k \rangle})$$

predict state one step ahead

$$\hat{\mathbf{P}}^{+}_{\langle k+1 \rangle} = \mathbf{F}_x \hat{\mathbf{P}}_{\langle k \rangle} \mathbf{F}_x^T + \mathbf{F}_v \mathbf{V} \mathbf{F}_v^T$$

project covariance one step ahead

prediction phase

$$\mathbf{v} = \mathbf{z}^{\#}_{\langle k+1 \rangle} - h(\hat{\mathbf{x}}^{+}_{\langle k+1 \rangle}, \mathbf{p}_i)$$

new information – innovation

$$\mathbf{K} = \mathbf{P}^{+}_{\langle k+1 \rangle} \mathbf{H}_x^T (\mathbf{H}_x \mathbf{P}^{+}_{\langle k+1 \rangle} \mathbf{H}_x^T + \mathbf{H}_w \mathbf{W} \mathbf{H}_w^T)^{-1}$$

how to distribute the innovation to states – Kalman gain

$$\hat{\mathbf{x}}_{\langle k+1 \rangle} = \hat{\mathbf{x}}^{+}_{\langle k+1 \rangle} + \mathbf{K} \mathbf{v}$$

state updated with innovation

$$\hat{\mathbf{P}}_{\langle k+1 \rangle} = \hat{\mathbf{P}}^{+}_{\langle k+1 \rangle} - \mathbf{K} \mathbf{H}_x \hat{\mathbf{P}}^{+}_{\langle k+1 \rangle}$$

updated covariance



update phase



IR: 4 – EJEMPLO FILTRO DE KALMAN

Localización con un mapa

```
close all
clear all
map=LandmarkMap(20); %mapa con 20 landmarks
uniformemente distribuidos en una region de +/-10m
xy
V=diag([0.02, 0.5*pi/180].^2); % matriz de
covarianza del modelo del robot
veh=Bicycle('covar',V); % modelo del robot
veh.add_driver(RandomPath(map.dim)); %genero
camino con puntos aleatorios
W=diag([0.1, 1*pi/180].^2); %matriz de covarianza
del sensor
sensor=RangeBearingSensor(veh, map, 'covar', W,
'angle', [-pi/2 pi/2], 'range', 4,'animate');
%sensor
P0=diag([0.005, 0.005, 0.001].^2) %covarianza de
estado inicial
ekf=EKF(veh,V,P0,sensor,W,map); % constructor del
filtro
ekf.run(250); %corre filtro
map.plot() %grafica mapa y landmarks
veh.plot_xy('b'); %grafica recorrido real "ground
truth"
ekf.plot_xy('r'); %grafica estimacion posición con
EKF
ekf.plot_ellipse('k'); % grafico elipces de
confianza 95% cada 20 muestras
figure();
pos=veh.x_hist %recupero posicion x,y,angulo en
una tabla
ekf.plot_error(); %grafico error y área de
confianza al 95%
a=sensor.landmarklog(); %registro de landmark
visible por el robot
figure();
plot(a); %grafico landmarks visibles
xlabel('Time step');
ylabel('Landmark');
```





Lo visto...

- Estimación bayesiana.
- Filtro de Kalman

Próxima clase:

- ROS.



Bibliografía:

- Robotics, Vision and Control Fundamental Algorithms in MATLAB. Peter Corke. 2da edición Springer.
- Introduction to Autonomous Mobile Robot. Roland Siegwart. 2da edición. MIT Press.